Tugas 1 Data Sains dan Analisis

Menelaah Data dengan Statistik

1. Menampilkan Data

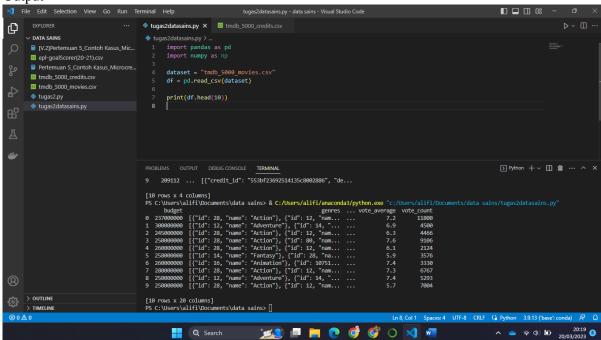
Source Code

```
import pandas as pd
import numpy as np

dataset = "tmdb_5000_movies.csv"

df = pd.read_csv(dataset)

print(df.head(10))
```



2. Menelaah Data

Source Code

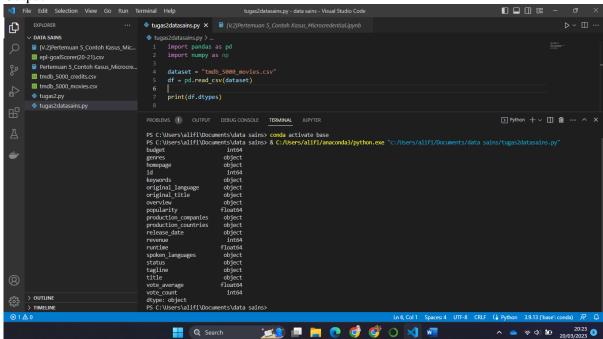
df.dtypes memungkinkan untuk melihat tipe-tipe data dari setiap kolom

```
import pandas as pd
import numpy as np

dataset = "tmdb_5000_movies.csv"

df = pd.read_csv(dataset)

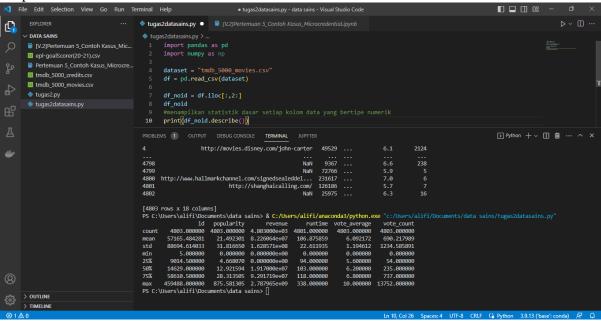
print(df.dtypes)
```



df_noid.describe() dapat menampilkan statistik dasar setiap kolom data yang bertipe numerik

```
df_noid = df.iloc[:,2:]
df_noid
#menampilkan statistik dasar setiap kolom data yang bertipe numerik
print(df_noid.describe())
```

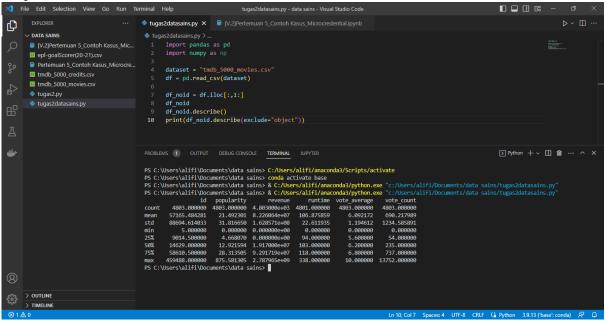
Output



Source Code

df_noid.describe(exclude="object") dapat menampilkan statistik kolom yang bernilai non-numerik dalam kolom dengan nilai mean, minimal, maksimal, quartil 1,2,3.

print(df_noid.describe(exclude="object"))



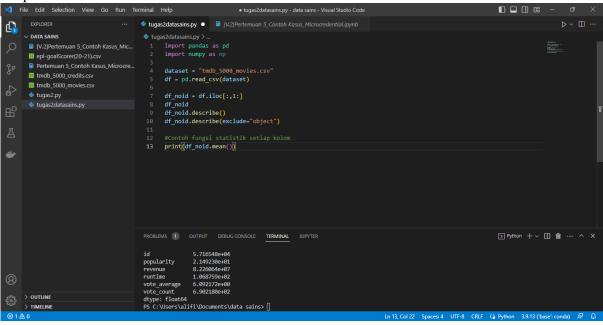
3. Fungsi Statistik

Source Code

Fungsi mean() digunakan untuk mencari nilai mean atau rata-rata.

print(df_noid.mean())

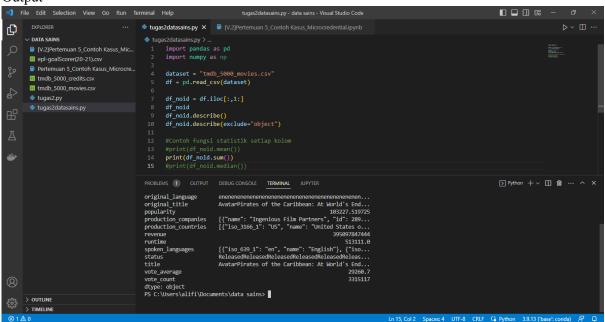
Output



Source Code

Fungsi sum() digunakan untuk menjumlahkan bilangan numerik berdasarkan kolom.

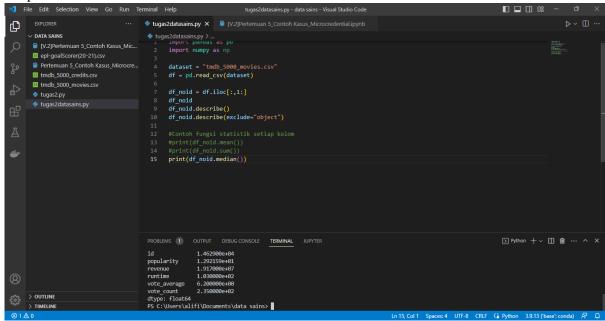
print(df_noid.sum())



Fungsi median() digunakan untuk mencari nilai tengah dari data yang bertipe numerik.

print(df_noid.median())

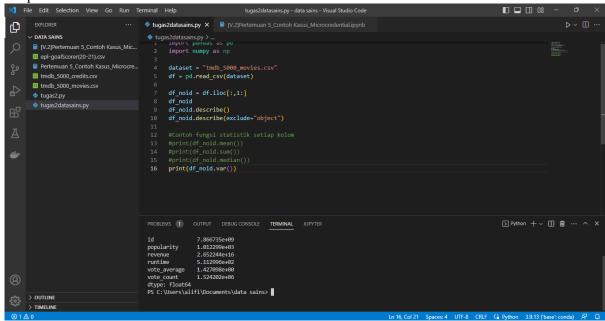
Output



Source Code

Fungsi var() digunakan untuk menentukan nilai varian.

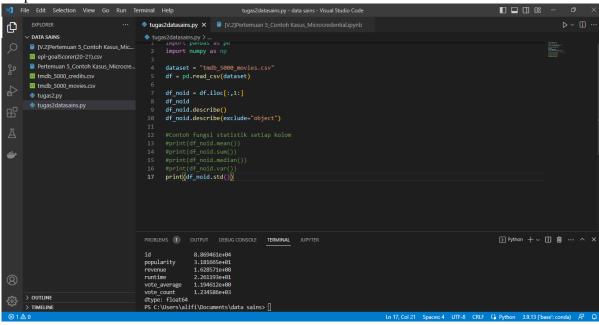
print(df_noid.var())



Fungsi std() digunakan untuk mencari nilai standar deviasi.

print(df_noid.std())

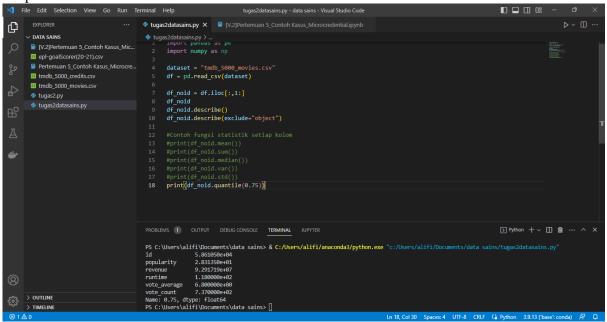
Output



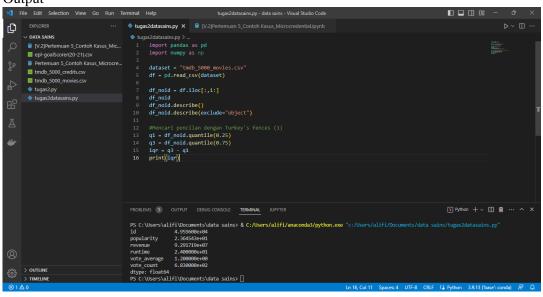
Source Code

Fungsi quartile(0.75) digunakan untuk menghitung nilai quartil 3. Sementara fungsi quartil 1 ialah quartile(0.25) sedangkan fungsi quartil 2 adalah quartile(0.5).

print(df_noid.quantile(0.75))

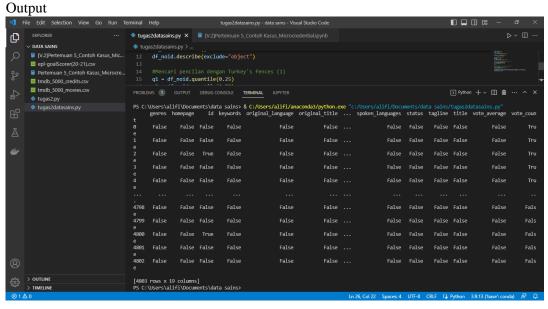


```
#Mencari pencilan dengan Turkey's fences (1)
q1 = df_noid.quantile(0.25)
q3 = df_noid.quantile(0.75)
iqr = q3 - q1
print(iqr)
Output
```



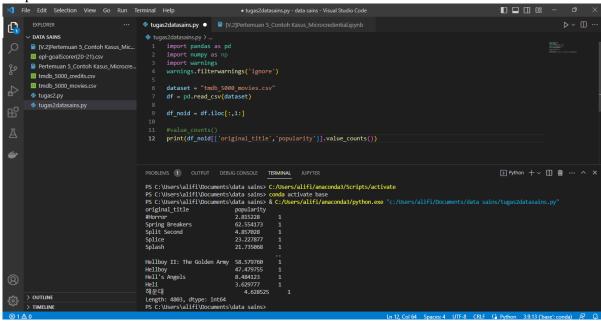
Source Code

```
#Mencari pencilan dengan Turkey's fences (2)
import warnings
warnings.filterwarnings('ignore')
# outlier filter
df_noid_align, iqr_new = df_noid.align(iqr, axis=1, copy=False,
join='outer')
outlier_filter = (df_noid < q1 - 1.5 * iqr_new) | (df_noid > q3 + 1.5 *
iqr_new)
print(outlier_filter)
```



print(df_noid[['original_title','popularity']].value_counts())

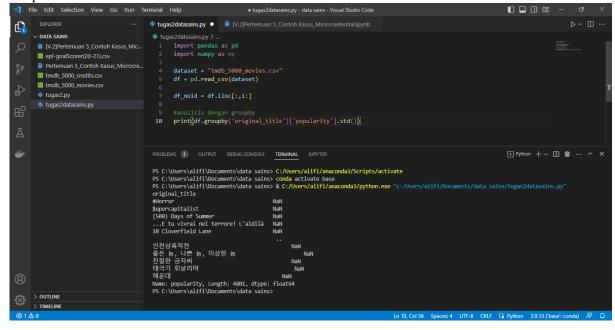
Output



Source Code

Menganalisis dengan metode groupby. Metode ini memungkinkan analisis dilakukan secara perkelompok berdasarkan nilai atribut yang sudah ditentukan, dalam source code menggunakan 'original_title' dan popularitasnya. Metode groupy yang digunakan ialah std() untuk mencari standar deviasi.

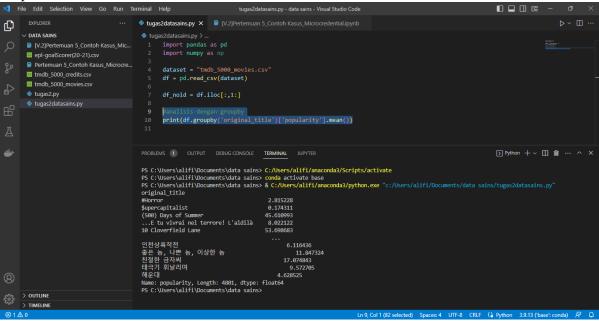
print(df.groupby('original_title')['popularity'].std())



Menganalisis dengan metode groupby. Metode groupy yang digunakan yaitu mean() untuk mencari nilai rata-rata dari atribut 'original title' dan popularitasnya'

```
print(df.groupby('original_title')['popularity'].mean())
```

Output



Source Code

Menggunakan metode corr() untuk menghasilkan table korelasi pearson antar kolom-kolom numerik. Rentang nilainya antara -1 sampai 1. Jika bernilai -1 artinya korelasi negatif, jika bernilai 0 artinya tidak ada korelasi linier, dan jika bernilai +1 artinya korelasi positif.

```
#Korelasi Pearson antara kolom-kolom numerik
print(df_noid.loc[:,'original_title':].corr())
```

